

GeoPT / Transolver 精度検証

SHIFT-Wing データセットによる学習・推論性能比較報告

小笹

2026 年 5 月 4 日

エグゼクティブサマリー

本実験では、AI を用いた空力解析サロゲートモデルの学習効率・精度向上を目的として、3 種類のモデルを比較評価した。

■ 主要な成果

- ・事前学習済みモデル（GeoPT Fine-tune）は、ゼロからの学習より推論精度が高かった。
- ・学習データ外（外挿）のケースでも GeoPT Fine-tune の優位性が確認された。
- ・改良アーキテクチャ（GeoTransolver）はゼロからの学習でも高い精度を示した。
- ・Pressure 誤差（中央値）は真値の 0.2% 以内を達成。

GeoPT とは

GeoPT は MIT CSAIL・清華大学の研究グループ（Kaiming He ほか）が開発した、物理シミュレーション向け AI 事前学習フレームワークである。航空機・自動車・船舶など工業形状を対象とした空力・流体解析において、少ない学習データで高精度な AI サロゲートモデルを構築することを可能にする。

GeoPT: Scaling Physics Simulation via Lifted Geometric Pre-Training

<https://arxiv.org/abs/2602.20399>

背景：CFD 学習データのコスト問題

CFD（数値流体計算）による学習データ生成は極めてコストが高い。例えば、自動車空力 1 サンプルの生成には約 6.1 万 CPU 時間を要する。これが AI サロゲートモデルの普及を妨げる主因となっている。

一方、3D 形状データ（ShapeNet など）は Web から大量かつ低コストで入手可能である。

GeoPT はこの形状データを活用しながら、CFD 計算なしで「物理らしい」学習データを合成する手法を提案した。

GeoPT の仕組み（Lifted Geometric Pre-Training）

従来の形状のみの事前学習では、流れや変形といった物理ダイナミクス情報が欠落するため、サロゲートモデルへの転用で性能が悪化する問題があった。GeoPT はこれを解決するため、形状データに「合成ダイナミクス」を付加した事前学習を行う。

ステップ	内容
① 形状の幾何特徴を計算	STL メッシュ上の各点から境界面までの距離・方向ベクトルを算出。 CFD ソルバーは不要。
② 速度場をランダム生成	ランダムな速度ベクトルを大量サンプリング。物理的に厳密である必要はない。
③ 粒子軌跡を計算	各点をランダム速度で移動させ、境界面に達したら停止（質量保存則の数学的骨格に対応）。
④ 教師データとして学習	軌跡上の幾何特徴時系列を教師信号として、「形状と空間の物理的相関」を学習させる。

この手法により、1 万形状から 100 万サンプル以上を約 3 日（80 コア）で生成できる。**CFD** 学習データ生成コストと比較して、桁違いのコスト削減を実現している。

事前学習とファインチューニングの役割分担

事前学習で身につけること	
	境界（壁面）の位置と形状認識
	境界周りの空間的相関構造
	形状が流れ場に与える影響の方向性
	質量保存則の数学的骨格（移流方程式への適合）
ファインチューニングで身につけること	
	実際の圧力・速度分布の値
	粘性・乱流の効果
	レイノルズ数・マッハ数依存性
	具体的な物理量の定量値

検証済みの効果

複数の公開ベンチマークで有効性が確認されている。

対象タスク	データセット	効果
自動車空力	DrivAerML	必要学習データ量 40%削減、収束速度 2 倍
航空機空力	NASA-CRM	必要学習データ量 20～60%削減
船舶水力学	DTCHull	収束速度 2 倍高速化

本実験では、この **GeoPT** 事前学習済みモデルを **SHIFT-Wing** 翼形状データセットを使ってファインチューニングし、その推論精度を **Transolver** および **GeoTransolver** のスクラッチ学習モデル（ゼロから学習したモデル）と定量比較し、その有効性を検証した。

1. 実験目的

AI 事前学習モデル（GeoPT）から Fine-tune した場合と、ゼロから学習した場合の性能差を、空力解析データを使って定量的に検証した。また、改良アーキテクチャである GeoTransolver についても、強力な比較基準として同条件で評価を行った。

本実験が解決しようとした問いは以下のとおりである。

- (1) GeoPT の事前学習は、最終精度を向上させるか？
- (2) 学習データ外の形状に対しても、精度優位性は保たれるか？
- (3) GeoPT から Fine Tune した Transolver と GeoTransolver とでの性能差はどの程度か？

2. 実験概要

2.1 比較対象モデル

公開されている GeoPT の事前学習モデルは、アーキテクチャとして Transolver を採用している。そのため本実験では、GeoPT 事前学習から Fine tune した Transolver モデルと、ゼロからフルスクラッチ学習した Transolver モデル、および、Transolver の改良アーキテクチャである GeoTransolver の 3 種について同一データセット・同一評価条件で比較した。

Case	モデル種別	学習方法	特徴
A	GeoPT-Transolver	GeoPT 事前学習から Fine-tune	事前学習の知識を活用。本実験の主軸。
B	Transolver	ゼロから学習 (Scratch)	同一アーキテクチャ。事前学習なし。基準モデルとして使用。
C	GeoTransolver	ゼロから学習 (Scratch)	改良アーキテクチャ。強力な比較基準として採用。

2.2 データと評価

SHIFT-Wing 翼形状データ 100 件を学習 80 件・検証 10 件・テスト 10 件に分割した。テストは形状パラメータ分布の端部（外挿領域）から意図的に選択しており、学習分布外での性能を評価する設計となっている。

評価対象は翼表面の圧力（Pressure）および壁面せん断応力（WSS）の推論値とし、いずれも物理量に換算してから誤差を算出した。

3. 結果

3.1 テスト平均精度

テスト 10 件の平均精度を以下に示す。数値が小さいほど誤差が少なく精度が高い。

モデル	Pressure 相対 L2	総合相対 L2 誤差	WSS 相対 L2	評価
A (GeoPT-Transolver)	0.00695	0.00695	0.1072	最良
B (Transolver)	0.00847	0.00847	0.1117	基準
C (GeoTransolver)	0.00715	0.00715	0.1071	A に次ぐ

A (GeoPT-Transolver) が Pressure・WSS 双方で最良の結果となった。C (GeoTransolver) はゼロからの学習でありながら基準モデル B を大きく上回り、A に肉薄した。

3.2 Pressure 誤差の分布

テスト全 10 件・全格子点 (約 1,623 万点) を対象にした Pressure 絶対誤差の分布を以下に示す。絶対誤差 [Pa] と真値に対する誤差割合 [%] を併記する。

パーセンタイル	A [Pa]	A [%]	B [Pa]	B [%]	C [Pa]	C [%]
	A (GeoPT Transolver)		B (Transolver)		C (GeoTransolver)	
中央値 (p50)	45.5	0.19%	47.1	0.20%	50.9	0.22%
p75	93.7	0.40%	97.9	0.42%	106.6	0.45%
p90	181.8	0.78%	196.9	0.85%	209.1	0.90%
p95	269.9	1.18%	298.8	1.32%	326.6	1.44%
p99	616.5	3.09%	651.7	3.25%	821.6	4.29%
p99.9	1,777.7	11.91%	1,875.3	13.22%	1,824.5	11.50%
最大値 (p100)	4,692.3	70.10%	6,095.9	89.99%	5,434.3	79.10%

中央値 (p50) では誤差割合がいずれのモデルも 0.2% 前後に収まる。p99 以上の外れ点では誤差割合が大きくなるが、全格子点の 99% 超は誤差割合 3~4% 以内であり、サロゲートモデルとして実用的な精度水準を示している。A (GeoPT Fine-tune) は B (Scratch) に対して全パーセンタイルで誤差が小さく、特に高誤差域 (p99 以上) での優位性が顕著。

※ 高誤差域の低減手法 (学習データ量・サンプリング数・重み付き Loss) の検討については、6 項の追加実験も参照のこと。




図1 テスト全体の Pressure 絶対誤差分布 (横軸は対数スケール)

3.3 代表ケースの可視化

モデル間の差異が最も大きかったケース（sample_000069）での **Pressure** 分布を示す。




図2 代表テストケースの **Pressure** 分布。左上から **Truth**（正解）、A、B、C。
A,B,C 全てにおいて 90% の範囲で誤差 1% 以下であるため、目視では大きな差異は見られない。



図3 同ケースの *Pressure* 絶対誤差分布 (単位: Pa)

目視上、**A** および **C** は真値の分布をほぼ再現しており、特に翼前縁・後縁付近の圧力変化の捉え方に差が現れた。

4. 外挿領域での推論性能

テストセットは学習データ分布の端部（外挿領域）から選択されている。形状パラメータ空間での「学習データからの距離」と「誤差」の相関を調べた。

距離の定義	A 誤差との相関	B 誤差との相関	B-A 差との相関
主成分（PCA1）外挿距離	0.135	0.060	-0.091
全パラメータ空間での最近傍距離	0.130	0.317	0.457
全パラメータ空間での 5 近傍平均距離	0.393	0.508	0.435

全パラメータ空間でみると、学習データから遠いケースほど **B** の誤差が **A** より増加しやすい傾向が示唆された。**GeoPT** 事前学習が外挿領域での汎化能力向上に寄与している可能性がある。ただし、テストは 10 件のみであり、追加検証での確認が必要である。




図4 外挿距離と **A**・**B** 誤差の関係

5. 考察・結論

5.1 事前学習の有効性

A (GeoPT Fine-tuned Transolver) は、同一アーキテクチャのゼロ学習 B (Scratch-Transolver) に対して Pressure・WSS 双方で優位な結果を示した。学習データ外の形状においても優位性の傾向が確認されており、GeoPT 事前学習は本データセットの特性に対して有効に機能していると考えられる。

5.2 アーキテクチャ改善の寄与

C (Scratch-GeoTransolver) は事前学習なしでも B を明確に上回り、A に接近した。アーキテクチャの改善だけでも大きな精度向上が得られることを示しており、今後は事前学習と改良アーキテクチャを組み合わせた検討も視野に入る。

5.3 今後の課題

- ・外挿距離依存性の統計的検証（複数データ分割・テスト件数の増加）
- ・GeoTransolver に GeoPT 事前学習を組み合わせた実験
- ・外挿方向の多様化によるロバスト性の評価

6. 追加実験：高誤差域の低減手法の検討

3.2 節で示したとおり、Pressure 推論において p99 以上の局所的な高誤差域が存在する。本追加実験では、その低減に向けた 3 つの手法を検証した。また、条件変更後もモデル間の性能傾向が維持されることを確認した。

検証観点	検証内容	主な結論
学習データ量	Train 40 件 vs 80 件で比較	データ量増加で全体精度・高誤差域ともに明確に改善
サンプリング数	point-budget 30k / 60k / 100k で比較 (GeoTransolver)	高誤差ピーク近傍の空間的広がりを局所化できる
モデル性能傾向	条件変更時の GeoPT-Transolver vs GeoTransolver の差の推移	条件が変わっても性能順位・傾向は維持される
重み付き Loss	固定・動的ホットスポット重みを GeoPT-Transolver・GeoTransolver に適用	既存高誤差領域の低減効果を確認。実用化にはパラメータ調整が必要

6.1 学習データ量の影響

学習に使用するデータ数を 40 件とした場合（以下 Train40）と 80 件とした場合（Train80）とを比較した。Val/Test は同一サンプル、評価は Test 外挿 10 ケースの全格子点（Full-mesh）で行った。

【GeoPT-Transolver】

指標	Train80	Train40	Train40 の悪化率
Pressure 相対 L2 誤差	0.00533	0.01095	+105.5%
RMSE [Pa]	62.3	127.9	+105.3%
Full-mesh MAE [Pa]	69.0	136.9	+98.4%
Full-mesh p99.9 絶対誤差 [Pa]	1,086.7	1,916.6	+76.4%
Full-mesh p99 絶対誤差 [Pa]	492.4	1,134.0	+130.3%
Full-mesh 上位 1%平均誤差 [Pa]	733.5	1,478.9	+101.6%

【GeoTransolver】

指標	Train80	Train40	Train40 の悪化率
Pressure 相対 L2 誤差	0.00603	0.01216	+101.6%
RMSE [Pa]	70.6	142.1	+101.5%
Full-mesh MAE [Pa]	88.9	160.8	+77.9%
Full-mesh p99.9 絶対誤差 [Pa]	1,205.6	2,365.0	+96.2%
Full-mesh p99 絶対誤差 [Pa]	599.3	1,283.8	+114.2%
Full-mesh 上位 1%平均誤差 [Pa]	861.4	1,747.5	+102.9%

GeoPT-Transolver・GeoTransolver 双方で、Train80 化により Pressure 相対 L2・RMSE が約半減し、Full-mesh の p99.9・p99・上位 1%平均もすべてのテストケースで改善した。

6.2 サンプル数の影響

GeoTransolver を対象に、学習時の point-budget（モデルあたりのサンプリング点数）を 30k・60k・100k で比較した。いずれも Train80、評価は Full-mesh。

指標	30k	60k	100k	30k→100k 変化
p99.9 絶対誤差 [Pa]	1,472.1	1,205.6	1,140.9	-22.5%
p99 絶対誤差 [Pa]	783.9	599.3	581.9	-25.8%
上位 1%平均誤差 [Pa]	1,081.4	861.4	826.9	-23.5%
最大絶対誤差 [Pa]	3,453.2	3,786.0	3,673.5	+6.4%

サンプリング数を増やすと、p99.9・p99・上位 1%平均は一貫して改善する。一方、最大絶対誤差は単調には低下しない。幾何的な分析では、最大誤差の 90%以上に相当する超高誤差領域は

30k→100k で p90 距離が約 87%、バウンディングボックス対角長が約 81%縮小した。すなわち、誤差ピーク自体は残るものの、その影響範囲が局所に収まる効果がある。

6.3 条件変更後のモデル性能傾向

学習データ量やサンプリング数が変わっても、GeoPT-Transolver は GeoTransolver に対して概ね 10～20%程度優位であることが各条件で確認された。

条件	GeoPT-Transolver	GeoTransolver	GeoPT の優位幅
Train80 / 30k 評価 (本文ケース)	0.00695	0.00715	-2.8%
Train80 / 60k 学習・100k 評価	0.00533	0.00603	-11.7%
Train40 / 60k 学習・100k 評価	0.01095	0.01216	-10.0%

本文 (3.1 節) で示した GeoPT-Transolver 優位の傾向は、データ数・サンプリング数の増減によらず維持された。GeoPT 事前学習の寄与は、条件変更に対してロバストであることが確認された。

6.4 ホットスポット重み付き Loss の効果

局所大誤差が発生しやすい領域 (ホットスポット) の Loss 重みを高める手法を試行した。固定ホットスポット重み (低圧側・翼端前縁側等を常時 1.25 倍) と、動的誤差重み (学習後半で誤差上位 1%点を 1.25 倍) の 2 方式を GeoPT-Transolver・GeoTransolver に適用した。

モデル	手法	Pressure 相対 L2	RMSE [Pa]	上位 1%平均 [Pa]	既存上位 1%領域 [Pa]
A	Baseline	0.006949	81.3	908.2	908.2
A	固定 weight 1.25	0.007233	84.6	875.6	721.6 ↓
A	動的 weight 1.25	0.007702	90.1	1,029.4	948.1
D	Baseline	0.007152	83.7	1,081.4	1,081.4
D	固定 weight 1.25	0.007806	91.3	1,148.0	964.8 ↓
D	動的 weight 1.25	0.007088 ↓	82.9 ↓	1,017.4 ↓	985.7 ↓

↓は Baseline より改善。A：固定 weight は既存上位 1%領域を 21%低減したが全体精度は悪化。D：動的 weight は全体精度・上位 1%平均・既存高誤差領域のいずれも改善した唯一の構成。ただし両モデルとも最大絶対誤差は安定して低下せず、固定 weight では別の箇所に新たなピークが発生する傾向が見られた。実用化には重み倍率・対象点割合・スケジューリング・空間的平滑化制約の設計が必要。

6.5 まとめ

- ① 学習データ量を増やすことで、全体精度・高誤差域ともに明確に改善する。
- ② サンプル数を増やすことで、誤差ピーク近傍の高誤差域を空間的に局所化できる（誤差ピーク自体の消去ではなく、影響範囲の縮小）。
- ③ データ量・サンプル数を変えても、GeoPT-Transolver の GeoTransolver に対する優位傾向は維持された。
- ④ 重み付き Loss は高誤差領域を下げる効果を確認したが、最大誤差の安定した低減にはパラメータ設計の追加検討が必要。